README · Predfy

Visão geral do repositório e quickstart

Predfy — HyperCopa DISEC 2026

Modelos preditivos sobre Licitação Eletrônica (Lei 13.303/16) para **apoiar decisões e minimizar riscos** em prazos, intercorrências (impugnação/recurso), atrasos e ruptura contratual.

Desenvolvido em conjunto pelos **Times 1 e 2 da ECOA do CESUP-Contratações** (Banco do Brasil) durante a HyperCopa DISEC 2026.

Time 1 — Modelos Analíticos: João 23 (capitão) · Francisco · Rosali · Silvia **Time 2 — Agente IA + RPA:** Bento 14 (capitão) · Felipe · Amélia · Vânia · Rafael

Visão de produção: integrar ao fluxo de trabalho e à plataforma do BB para indicar preventivamente riscos e prazos reais. Acoplado ao Agente Predfy, o app se generaliza para qualquer extrato/domínio.

⚖️ **Avaliadores da banca: comece por** `docs/COMO_AVALIAR.md`. O **Modo demonstração offline** (sem chave de LLM externa) cobre toda a jornada. Uma chave brinde para o Caminho A será encaminhada por canal seguro.

O que esse repositório entrega

Uma **jornada de 7 passos** que conduz o usuário do dado bruto à decisão acionável:

```
0. Construção dos dados sintéticos (Faker + regras Lei 13.303, seed=42)
       ↓
1. Agente Predfy (Teams ou local)  — feature engineering visível,
                                          escolha de target, formulação
                                          da pergunta preditiva
       ↓
2. Treino H2O AutoML  — compara GBM, GLM, XGBoost, RF; entrega o líder
       ↓
3. Avaliar o modelo  — leaderboard, métricas no teste, importância
       ↓
4. Baixar pacote da entrega  — ZIP único: relatório HTML + JSON + summary
       ↓
5. Interpretar resultado  — agente Teams (simulado ou real) ou OpenAI
                             traduz métricas em recomendações de negócio
       ↓
6. Testar em evento real  — EAP nova hipotética, predição com semáforo
```

A jornada tem **3 caminhos** para a fase conversacional, escolhidos na sidebar:

Caminho	LLM	Quando usar
A	OpenAI direto (chat embutido)	Dev local com chave própria
B	Microsoft Copilot do Teams	Produção BB (acordo M365)
C	**Modo demonstração offline**	**Avaliação da banca — sem chave OpenAI, sem rede**

O que você verá no app (UX da jornada)

Quando o app sobe (`http://localhost:8501`), a banca encontra **quatro elementos visuais** que orientam a avaliação:

Elemento	Onde fica	O que faz
Stepper de 7 etapas	Topo de toda a página	Sete círculos numerados (0–6) na paleta BB; o atual em **amarelo** `#FAE128` , os concluídos em **azul** `#003DA5` , os futuros em cinza. Marca o progresso em tempo real.
Banner amarelo "Modo demonstração"	Logo abaixo do header, quando o toggle da sidebar está ativo	Avisa que a sessão é Caminho C (offline, seed=42, cenário canônico DICOI).
Semáforo de risco · Etapa 6	Centro da Etapa 6	Três cards clicáveis (cenários DICOI / DISEC / DITEC) → predição com 🟢 baixo · 🟡 médio · 🔴 alto risco + recomendação operacional + botão "Pedir interpretação".
Botão único " 📦 Baixar pacote"	Etapa 4	Gera **um único ZIP** com `relatorio.html` , `relatorio.json` , `summary.md` , `como_reproduzir.txt` e o `MVP_CANVAS.md` / `.docx` . É o anexo da entrega oficial.

> **Contexto legal.** Toda a terminologia (EAP, EAPs Padrão, Etapas, Licitação Eletrônica, Aditivo, Intercorrência) reflete a **Lei 13.303/16 — Lei das Estatais**. Glossário completo em `docs/MVP_CANVAS.md` §8.

Segurança e privacidade — leia antes de clonar

Este repositório foi **revisado e anonimizado** para distribuição pública à banca avaliadora. **Nenhum dado real do Banco do Brasil ou pessoal está incluído.**

O que NÃO está no repo	O que ESTÁ no repo
❌ Dados reais de Licitação Eletrônica BB	✅ Dados 100% sintéticos gerados por código (Faker + regras Lei 13.303)
❌ CPFs, CNPJs, valores nominais reais	✅ Identificadores e CNPJs gerados artificialmente
❌ Nomes completos da equipe	✅ Apenas papéis ("Capitão da Equipe") e codinomes
❌ Chaves OpenAI ou de qualquer API	✅ Apenas `.env.example` (template vazio)
❌ Logs de produção, dumps de banco, screenshots de sistemas BB	✅ Apenas saídas geradas localmente pela jornada da demo
❌ Documentos com classificação interna BB	✅ Apenas o MVP Canvas e relatórios gerados pelo MVP

Outras camadas de proteção embutidas: - `.gitignore` bloqueia `.env`, `dados reais/`, `dados_reais_limpos/`, PDFs, modelos H2O salvos e relatórios gerados. - **Sandbox de execução**: o agente roda código `pandas` em `exec()` com globals restritos — sem `os`, `subprocess`, rede, abertura de arquivos. - **Caminho A** (OpenAI): apenas schema + ≤ 20 linhas de amostra trafegam para o LLM. CSV inteiro nunca sai do laptop. - **Caminho B** (Copilot Teams): em produção BB, trafega no tenant M365 sob acordo Microsoft↔BB com auditoria Microsoft Purview. - **Caminho C** (Modo demo): zero chamadas externas — todas as respostas do agente são pré-gravadas e versionadas em `docs/demo/script_turnos.json`.

Após o Pitch Day (10/06/2026), este repositório pode ser convertido para privado sem prejuízo para os avaliadores que já testaram.

Pré-requisitos

Item	Versão	Como verificar
Python	3.10, 3.11 ou 3.12 (3.13/3.14 podem precisar afrouxar pins do `requirements_app.txt`)	`python --version`
Java JDK	17 ou 21 (o H2O exige Java; sem isso o treino não inicia)	`java -version`
Memória RAM	≥ 4 GB livre	—
Espaço em disco	≥ 2 GB livres (h2o + venv)	—

> Se a máquina não tem Java, baixe o JDK 21 ZIP portátil e descompacte numa pasta — não precisa instalar como administrador. Adicione `bin\` ao `PATH` da sessão antes de iniciar o app.

Quickstart — sem chave OpenAI (Modo demonstração da banca)

A jornada inteira roda offline, com cenário pré-curado "*EAP DICOI / vai atrasar?*" e **resultado idêntico em qualquer máquina** (seed=42).

Windows (PowerShell)

Cole **uma linha por vez** (não cole o bloco inteiro — quebras de linha podem fragmentar URLs):

```
git clone https://github.com/FranMarteen/hypercopa-disec-mvp.git
```

```
cd hypercopa-disec-mvp
```

```
python -m venv .venv
```

```
Set-ExecutionPolicy -Scope Process -ExecutionPolicy Bypass -Force
```

```
.\.venv\Scripts\Activate.ps1
```

> Esperado: o prompt vira `(.venv) PS C:\...\hypercopa-disec-mvp>` . Se não aparecer `(.venv)` , o venv não ativou.

```
python -m pip install --upgrade pip
```

```
pip install -r requirements_app.txt
```

> Demora 3-7 minutos (o H2O tem ~250 MB).

```
streamlit run app_agente_bb.py
```

> Abre `http://localhost:8501` no navegador. Na sidebar, ative o toggle 🎓 **Modo demonstração da banca** e siga a jornada de 7 etapas.

Para encerrar: `Ctrl+C` no PowerShell. Para sair do venv depois: `deactivate` .

Linux / macOS (bash)

```
git clone https://github.com/FranMarteen/hypercopa-disec-mvp.git
cd hypercopa-disec-mvp
python3 -m venv .venv
source .venv/bin/activate
python -m pip install --upgrade pip
pip install -r requirements_app.txt
streamlit run app_agente_bb.py
```

Solução para erros comuns

Erro	Solução
`Activate.ps1 cannot be loaded — execution policies`	Rode `Set-ExecutionPolicy -Scope Process -ExecutionPolicy Bypass -Force` antes
`Could not find a version that satisfies h2o==3.46.0.6` (em Python 3.13/3.14)	Edite `requirements_app.txt` e troque `==` por `~=` no `h2o` e `scikit-learn`, ou use Python 3.10–3.12
`H2OConnectionError: Java not found`	Instale o JDK 17 ou 21 e reabra o terminal
`MemoryError` ao iniciar H2O	Feche outros apps; H2O precisa de ~2 GB livres
App carrega mas modo demo não pré-carrega CSV	Garanta que `dados_sinteticos/contratos.csv` existe (ele vem versionado no repo)

Pacote em PDF (offline) e zipão único da entrega

Toda a documentação está disponível como **PDF renderizado** (com diagramas Mermaid embutidos como vetores) em `docs/pdf/`. É o conteúdo recomendado para a banca **imprimir, anexar a e-mail ou abrir sem clonar o repo**.

Arquivo	Conteúdo
`docs/pdf/COMO_AVALIAR.pdf`	Roteiro narrado dos 7 passos (entregar primeiro à banca)
`docs/pdf/README.pdf`	Este documento
`docs/pdf/MVP_CANVAS.pdf`	MVP Canvas com glossário Lei 13.303/16 (§8)
`docs/pdf/RELATORIO_SOLUCAO.pdf`	Relatório técnico estendido (arquitetura, privacidade, ROI)
`docs/pdf/ENTREGA_TIME1_MODELOS.pdf` · `docs/pdf/ENTREGA_TIME2_AGENTE.pdf`	Entregas comparativas dos dois times
`docs/pdf/FLUXOGRAMA.pdf`	Diagramas Mermaid dos 3 caminhos (A/B/C)
`docs/pdf/DIAGRAMAS.pdf`	5 diagramas Mermaid (jornada, privacidade, sequência, tecnologias, produção)
`docs/pdf/PREDFY_OVERVIEW.pdf`	1-pager visual com identidade BB
`docs/pdf/diagramas/*.pdf`	Cada fluxograma como PDF standalone (12 arquivos)

Pacote único para o capitão submeter à banca: `entregas/Predfy_Banca_Entrega.zip` reúne todos os PDFs + screenshots + relatório de exemplo num único arquivo (~ 4 MB).

Para **regerar** os PDFs e o zipão localmente após qualquer ajuste nos `.md`:

```
npm i -g @mermaid-js/mermaid-cli   # uma vez
pip install markdown                # uma vez
python gerar_pdfs.py
python gerar_zipao_banca.py
```

Reprodutibilidade

A banca clona, instala e **vê os mesmos números** que a equipe.

- `np.random.seed(42)` e `random.seed(42)` em todos os geradores.
- `random_state=42` nos splits treino/teste.
- `H2OAutoML(seed=42)` no AutoML.
- Versões pinadas em `requirements_app.txt` (h2o==3.46.0.6, scikit-learn==1.5.2).
- Dados sintéticos em `dados_sinteticos/` versionados — banca não precisa regerar para reproduzir.

Para confirmar a reprodutibilidade, ver checklist em `docs/COMO_AVALIAR.md`.

Estrutura

```
hypercopa-disec-mvp/
├── app_agente_bb.py           ← APP STREAMLIT (entregável principal)
├── requirements_app.txt       ← deps pinadas
├── .env.example               ← template (chave OpenAI opcional)
├── .gitignore                 ← protege segredos e binários
│
├── dados_sinteticos/          ← UNIVERSO DE LICITAÇÃO ELETRÔNICA (sintético)
│   ├── eaps.csv               ← 2.500 EAPs
│   ├── contratos.csv          ← 1.959 contratos pós-assinatura (cenário banca)
│   ├── etapas_eap.csv         ← 21.884 etapas detalhadas
│   ├── participantes.csv      ← 11.645 participantes em certames
│   ├── fornecedores.csv       ← 300 fornecedores
│   ├── eaps_padrao.csv        ← 47 etapas-padrão por categoria
│   └── SCHEMA.md              ← dicionário de dados em PT-BR
│
├── gerar_dados_sinteticos_eaps.py  ← regenera os CSVs (seed=42)
├── gerar_dados_postgres.py         ← versão relacional com UUIDs
│
├── modelos_preditivos.py      ← 3 modelos do MVP (Prazo · Intercorrência · Ruptura)
├── modelos_mvp_base.py        ← código de referência da modelagem
├── analise_clusters.py        ← análise K-Means de recorrência (protótipo)
│
├── notebook_h2o_agente_mvp.ipynb   ← jornada como notebook (alternativa CLI)
├── demo_jornada.py            ← jornada via CLI sem UI
│
├── docs/
│   ├── COMO_AVALIAR.md        ← ⭐ ROTEIRO PARA A BANCA
│   ├── MVP_CANVAS.md / .docx  ← MVP Canvas (template HyperCopa)
│   ├── ENTREGA_TIME1_MODELOS.md / .docx   ← entrega comparativa Time 1
│   ├── ENTREGA_TIME2_AGENTE.md / .docx    ← entrega comparativa Time 2
│   ├── RELATORIO_SOLUCAO.md / .docx       ← documento técnico estendido
│   ├── FLUXOGRAMA.md          ← diagramas Mermaid dos caminhos
│   ├── ACESSO.md              ← pré-requisitos e instalação detalhados
│   ├── COPILOT_STUDIO_GUIA.md ← passo-a-passo para publicar agente no Teams
│   ├── agente/                ← system prompt + tools schema (Caminho A)
│   └── demo/
│       └── script_turnos.json ← turnos pré-gravados do Modo Demo (Caminho C)
│
├── teams_copilot/
│   ├── instructions.md        ← system prompt do Copilot Studio (Caminho B)
│   ├── declarative-agent.json ← manifest do agente declarativo
│   └── actions_openapi.yaml   ← OpenAPI das actions
│
├── api/main.py                ← API REST (FastAPI) para evolução futura
└── relatorios/                ← saídas geradas (gitignored)
```

Modos de uso

1. Modo demonstração (Caminho C) — recomendado para a banca

Sem chave OpenAI, sem rede externa, resultado idêntico a qualquer máquina.

1. Ative o toggle "🎓 **Modo demonstração da banca**" na sidebar.
2. CSV pré-carregado: `contratos_dicoi.csv` (1.959 contratos).
3. Avance turnos do agente com ▶ **Próximo turno** até gerar o CSV final.
4. Treine na Etapa 2 (budget 60s).
5. Baixe o **pacote completo da entrega** (Etapa 4).

2. Caminho A — OpenAI direto (chave própria)

Cole sua chave em `.env` (use `.env.example` como template) e inicie o app. O modo demo deve estar desligado.

3. Caminho B — Copilot do Teams

Para uso em produção BB. Veja `docs/COPILOT_STUDIO_GUIA.md` para publicar o agente no tenant M365.

Privacidade e segurança

- **Dados sintéticos** — nenhum dado real BB neste repositório.
- **Chave OpenAI** — fica em `.env` local (gitignored), não viaja com o código.
- **Caminho A**: somente schema + ≤ 20 linhas de amostra trafegam para OpenAI.
- **Caminho B**: CSV completo nunca sai do laptop; apenas amostra trafega no tenant M365 BB.
- **Sandbox de execução**: `exec()` com globals restritos, sem `os`, `subprocess`, rede.

Os 3 modelos preditivos do MVP

#	Modelo	Tipo	Target	Pergunta de negócio
1	**Prazo / Atraso**	Regressão GBM	`prazo_total_dias` (eaps) ou `teve_atraso` (contratos)	"Quanto tempo / vai atrasar?"
2	**Intercorrência**	Classif. binária GBM	`tem_intercorrencia`	"Vai ter impugnação/recurso?"
3	**Ruptura contratual**	Classif. binária GBM	`teve_rescisao`	"Risco de rescisão?"

O cenário canônico do **modo demonstração** usa o **Modelo 1 binário** (`teve_atraso`).

Licença e uso

Propriedade do Banco do Brasil. Repositório de uso interno da equipe HyperCopa DISEC 2026, **publicado para fins de avaliação da banca HyperCopa**. Após o Pitch Day (10/06/2026), pode ser convertido para privado.

Equipe HyperCopa DISEC 2026 · CESUP-Contratações · Banco do Brasil